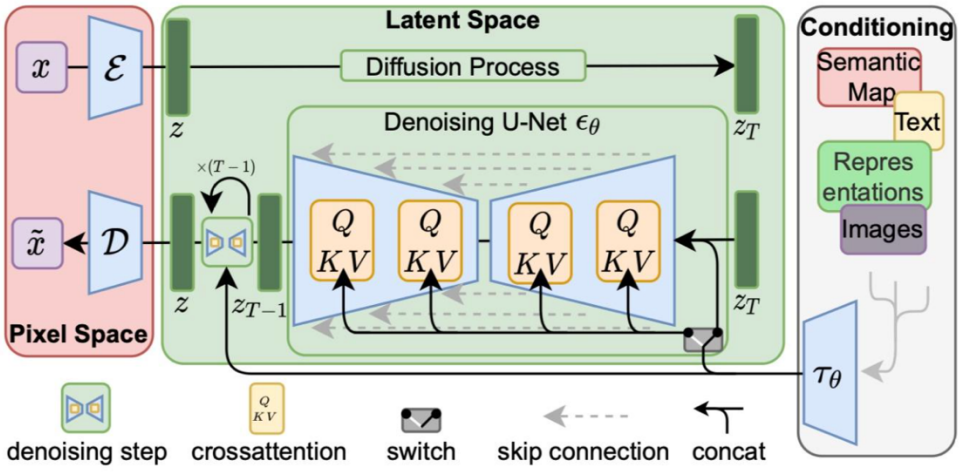
LDM：Latent Diffusion Model

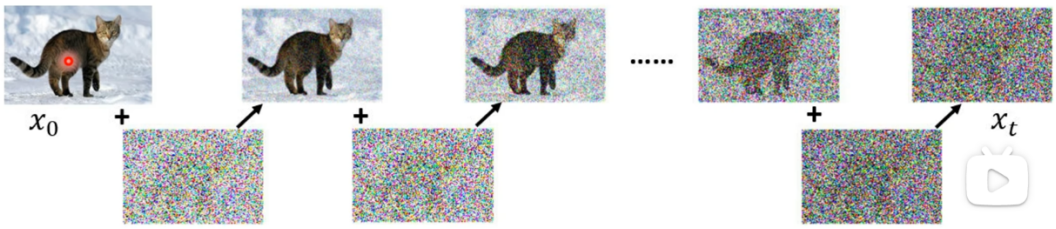


LDM 有三个主要模块

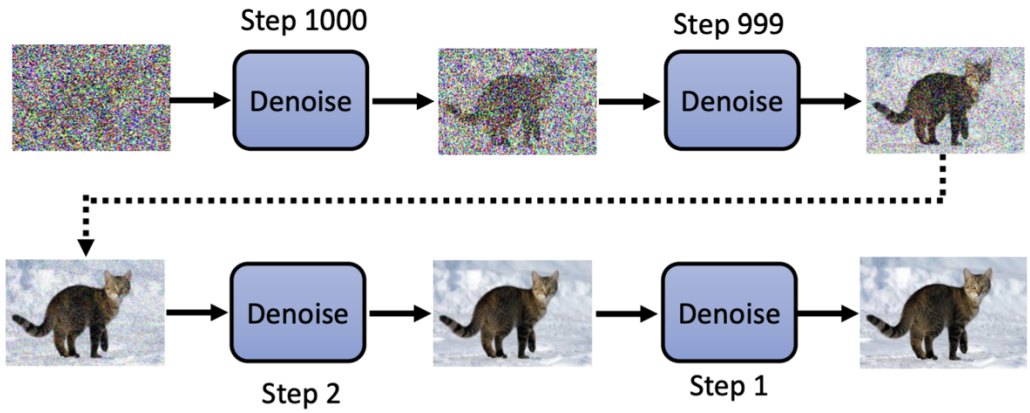
- 感知图像压缩（Perceptual Image Compression）：最左侧红框部分是**一个 VAE 模型**，encoder 用于将输入图像 x 编码为一个离散特征 z，decoder 用于从 z'还原出 x'。
- LDM：中间绿色部分是在**潜变量空间的扩散模型**，其中上半部分是多步骤的加噪过程，用于将特征 z 加噪为 zT 。下半部分是多步骤的去噪过程，每一步去噪的核心结构是一个由交叉注意力（Cross Attention）组成的 U-Net，用于将 zT 还原为 z 。
- **条件机制（**Conditioning Mechanisms）：右侧是一个条件编码器，用于将图像，文本等前置条件编码成一个特征向量 τθ ，并将其送入到扩散模型的去噪过程中。

Diffusion Model 扩散模型

- Diffusion Model 也是一个图像生成模型，其训练的过程是
  - **加噪过程：**从原始图片 x0 开始，以 t 个时间步加入高斯噪声数据（x1，x2…xt），直到整个 xt 图像变成一个高斯噪声（标准正态分布的噪声）。

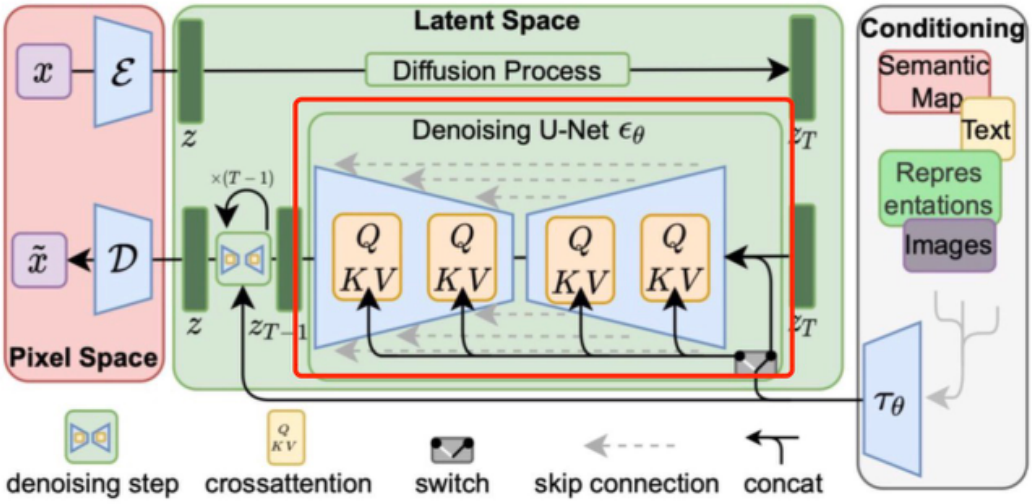


    - 在 Diffusion 里说的高斯噪声就是一个和原图片大小相等的二维度矩阵，比如图像是 600x400 像素，那高斯噪声就也是 noise[600][400]的二维矩阵，这里边的所有的 240000 个数字满足均值=0，方差=1 （标准正态分布，也叫高斯分布。这个具体的二维矩阵就是从 N(0,1)这个分布中随机采样出的一组数据）。
    - 加噪音的每一步就是将采样出的高斯噪音以一定的比例混合到原来的图像中，得到一个模糊一点的中间图像。（混合的方式就是每个数据点的值按照比例加和就可以）
    - 加噪步骤最后的结果就是把图像加成了一个符合 N(0,1)分布的二维矩阵数据（就是变成了一个高斯噪音，也叫纯噪音）。
  - **去噪过程**：从 xt 开始，以 t 个时间步每一步去除噪音，，直到数据还原成原始图片 x0



-
- 去噪音的过程就是，从一个纯噪音图像作为第一步的输入（即符合 N(0,1)分布的随机的一个噪音），然后**通过模型预测出**一个噪音（**注意**这个是模型预测出来的，而不是从 N(0,1）采样出来的高斯噪音，然后从前一步输入中减去这个噪音（即每个像素点的值减去噪音对应的这个点的值），得到一个新图像。重复这个过程（加噪音用了多少步，去噪音也用多少步）。
- 训练数据集中的每张图片都经过加噪/去噪的过程，结果是让模型学会如何能在去噪过程预测出每一步的准确的噪音。

  - **Loss 函数**
    - 最终恢复出来的图片和加噪音之前的原始图片能够差别最小
    - 同时去噪步骤模型**预测出来的噪音**跟加噪过程中加入的噪音之间也差别最小
    - 这样经过训练，就训练出了预测噪音的函数最贴合的参数值，也就是学会了如何预测噪音（指去噪步骤每一步的噪音）。
  - **生成新数据**
    - 当模型训练完，学会如何预测噪音之后（即去噪步骤生成噪音的函数的参数都得到了合适的值），就可以根据用户的需求（比如你的需求是生成一只猫的图片），从一个纯噪音（高斯噪音）开始，一步步去噪得到一只猫了。
- **Denoise module**
  - Diffusion 的加噪音过程，因为每一步加入的都是高斯噪音，所以 xt 是可以直接计算出来的。
  - 去噪过程的每一步需要去除掉的噪音是需要模型预测的，这部分 Denoise Module 是一个 UNET 类型的神经网络。
    - 指红色框的部分，每个时间步去噪都会经过这个过程，这个步骤中也会混入一些文本或者其他类型的条件向量（以实现条件控制，即学会根据条件要求生成复合条件的去噪过程的噪音，这样未来可以用户通过文本条件要求生成“一只会飞的猫”）



- 细节结构如下：中间包含卷积/残差连接/反卷积的过程，形似 U 型，所以叫做 UNet。
- 这个 Module 的网络参数，就是训练的结果，通过这些训练后的参数，这个模型就能生成复合条件的去噪噪音以完成去噪生成指定图片的过程。
- 