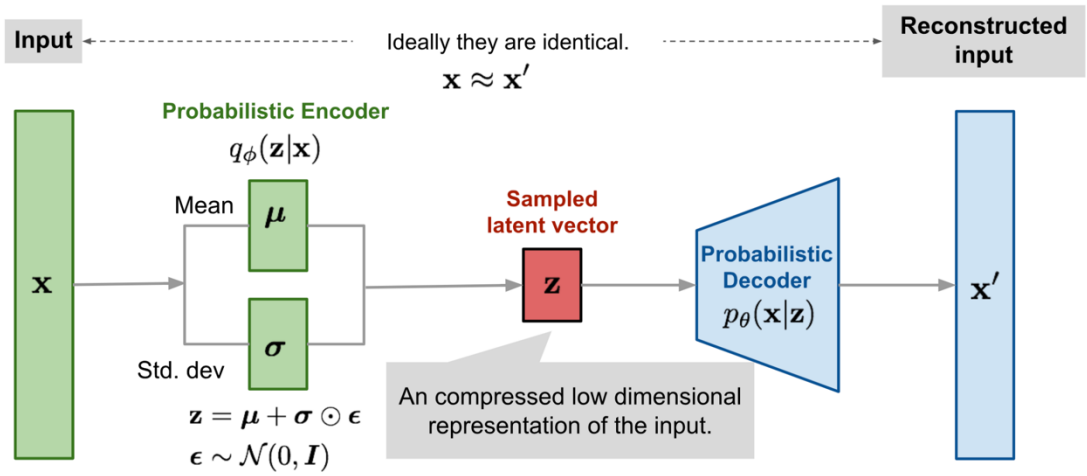
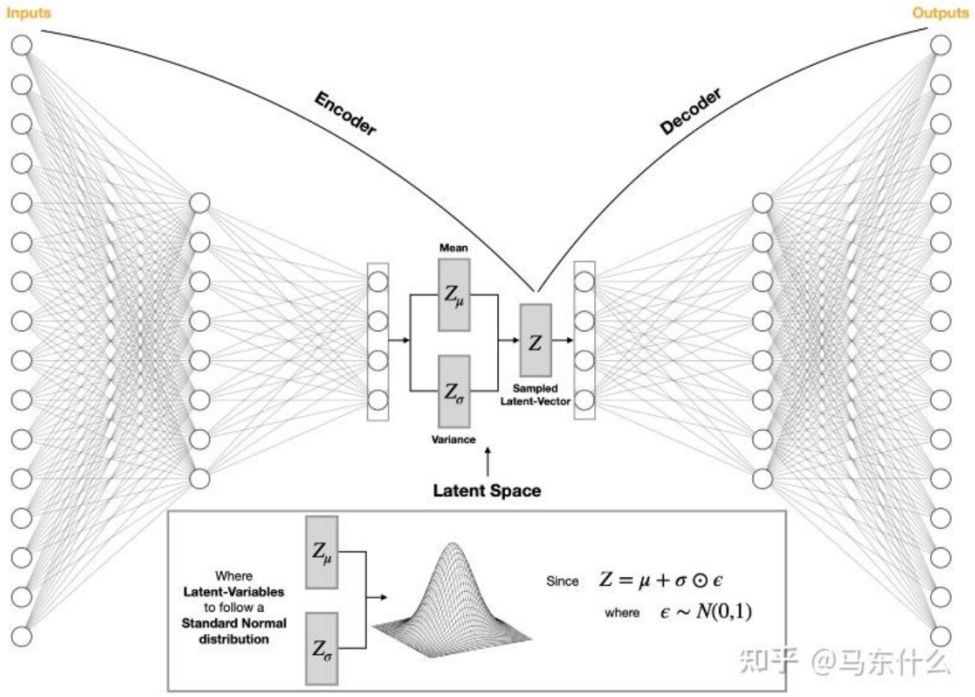
VAE 是一种**图像生成模型的框架。**

- 比如看了 1000 张猫的图片，它能自己生成一张全新的、从没见过的猫；
- 比如看了 1000 个手写数字“5”，它能生成一个你从没见过但依然能认出是“5”的数字。

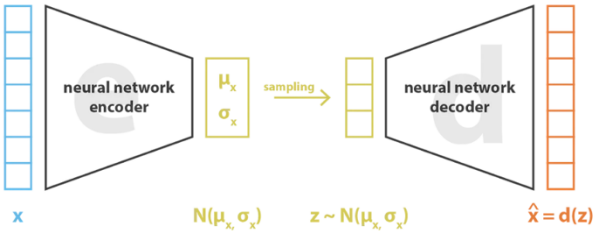




VAE 的网络结构

VAE 的结构包括

- 一个 Encoder：Encoder 进行数据降维（压缩），原始数据（比如一张图像）输入到 Encoder，输出是一个数据分布（latent space 的数据分布）。
    - VAE encoder 是一个概率模型 encoder（Probabilistic Encoder），因为其输出的是一个数据分布。
- 一个 Decoder：Decoder 进行数据升维（恢复），从数据分布中采样一个数据（latent data），输入到 Decoder，试图恢复出原始图像。



$$loss = ||x - \hat{x}||^2 + KL[N(\mu_x, \sigma_x), N(0, I)] = ||x - d(z)||^2 + KL[N(\mu_x, \sigma_x), N(0, I)]$$

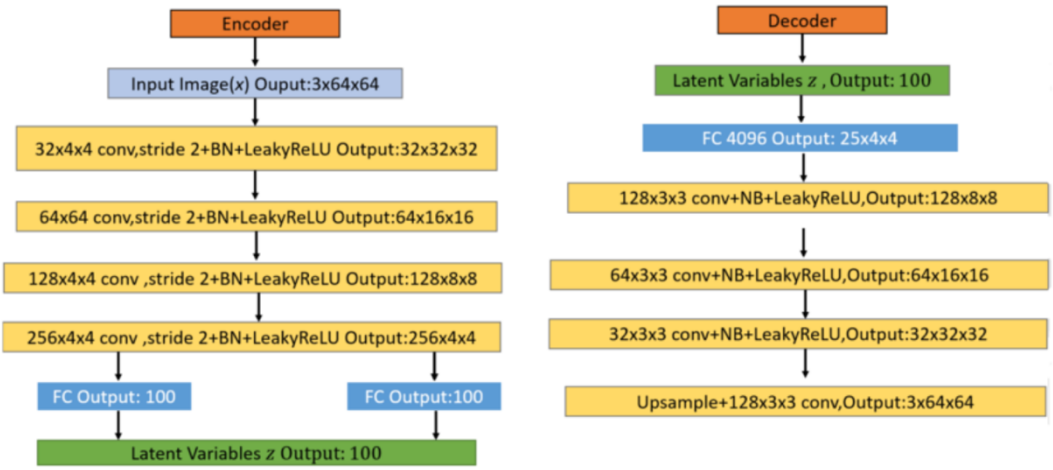
变分自编码器中，损失函数由重构（reconstruction）项（使编码解码方案高效）和正则化项（使潜在空间表示符合正态分布）组成。

- **从某个分布中采样数据**的意思是：以图片为例，原始图片 3x512x512（彩色图像 RGB 三通道，长宽都是 512 像素），经过 Encoder 降维后假设 latent representation 尺寸为 32x32，经过训练得到 latent representation 的数据分布。我们从这个分布中采样一个数据，就是**指的是从这个分布中生成随机数的过程，**每个随机数都是**根据正态分布的概率密度函数独立选择的，**保障其中的所有数据的均值和标准差符合此分布。比如根据这个分布采样一个 32x32 的矩阵数据（符合此分布的均值和标准差），然后通过 decoder 升维恢复成 3x512x512 的图像。

- **Loss 函数**：VAE 的损失函数有两部分组成
  - $loss = ||x - \hat{x}||^2 + KL[N(\mu_x, \sigma_x), N(0, I)] = ||x - d(z)||^2 + KL[N(\mu_x, \sigma_x), N(0, I)]$
  - **重建损失 Reconstruction**：生成数据与原始数据的差异（比如 MSE）
  - **正则化项**：Encoder 输出的潜空间数据分布符合标准正态分布（使用 KL 散度衡量两个分布之间的差异）
  - 也就是说，**VAE 训练目标**是让生成数据尽可能与原始数据贴近，且中间的潜空间数据分布尽可能贴近标准正态分布。
- 训练完成后，从标准正态分布采样一组数据，就可以通过 Decoder 生成一个和训练数据相似的数据。
  - 比如，使用 1000 张猫的照片训练出一个 VAE 网络后，从正态分布采样一组数据，通过 Decoder 就可以生成一个新的猫的图片。

VAE Encoder & Decoder

- VAE 的 encoder 和 decoder 的具体结构，可以根据不同的数据类型和不同的目标自己去定义
  - 比如下面的示例是针对图像数据设计的，一个通过 4 个卷积层+1 个全连接层定义的 encoder，4 个反卷积层+1 个全连接层定义的 decoder



- 根据输入数据类型，常用的网络结构类型
  - **图像**：常用 CNN（卷积网络）作为 Encoder，转置卷积网络作为 Decoder
  - **文本**：常用 RNN/LSTM/Transformer 作为 Encoder，自回归网络作为 Decoder
  - **结构化数据**（如表格）：常用全连接网络（MLP）
- 根据任务复杂度
  - 简单任务（如 MNIST）：几层卷积 / 全连接即可
  - 复杂任务（如高分辨率图像生成）：需要更深的网络（如 ResNet、UNet）或注意力机制

我的项目中，VAE 的用途

- 音乐文件转换成频谱图（图像数据）之后，送入一个 VAE 网络，VAE encoder 压缩图像，得到 latent representation（潜空间数据表示）的概率分布（这部分就是上面描述的 VAE encoder 所做的事情。
  - 假设没有 Diffusion 的过程，从概率分布中采样一组数据，通过 VAE decoder 恢复图像，loss=得到的图像与原图像的重建差异+潜表示的概率分布与高斯分布的 KL 散度
    - 训练之后，就可以从高斯分布中采样一个数据，然后通过 VAE decoder 生成一个音乐频谱图了。
  - 现在有 Diffusion 的过程，相当于从概率分布中采样一组数据，送入到 Diffusion module 中进行处理，处理之后的数据再通过 VAE decoder 恢复图像。
    - Diffusion 本身也是一个图像生成模型，也是 Encoder（加噪音）+Decoder（去噪音）的结构，相当于使用了 VAE encoder 压缩后的潜空间数据去做 Diffusion，这样数据量更小，同时也利用了 Diffusion 的能力增强了图像生成的效果。
- 因此我的项目中，是在 VAE 结构中嵌入了一个 Diffusion 结构。

VAE 背后的数学原理

- VAE https://www.vectorexplore.com/tech/auto-encoder/vae.html
- KL 散度 https://www.vectorexplore.com/tech/loss-functions/kl-divergence/