VAE（Variational Auto-Encoder）

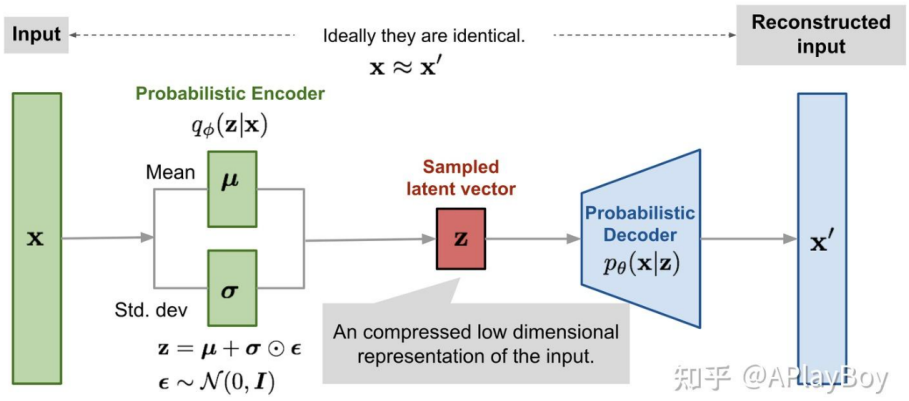


图 9：多元高斯分布的variational autoencoder模型

Training

训练数据：x：图片，标签等

训练过程：

- 编码器：目标是训练出 q(z, v)，（其中 v: μ, σ^2），所以也会写成 $q(z, \mu, \sigma^2)$
  - ✧ 编码器网络是由一系列的神经元层组成，比如卷积层（用于提取图片特征 ）和全连接层等。通过这些层的线性变换和激活函数运算，编码器最终输出两个参数：均值μ, 方差σ^2
  - ✧ 使用μ, σ^2采用得到隐变量 z，实际 z 就可以理解为一个低维的可以表征输入图片 x 的关键特征的数据。注意 VAE 编码器网络不是直接对 x 降维得到 z（AutoEncoder 是这样直接降维的），而是训练均值μ, 方差σ^2，再采样得到 z，这样可以有更强的泛化性和多样性。
- 解码器：目标是训练出 p(x|z)条件分布，即已发生 z 的条件下 x 的概率分布。
  - ✧ 解码器网络也是由一些列神经元层组成，比如可以是一个多层感知机结构，功能是从一个低维隐变量 z 映射到一个高维的图片 x。
- Loss 损失函数：
  - ✧ VAE 主要目的是学习数据的潜在分布，通过重构输入数据来优化模型。其损失函数由**重构损失**和 **KL 散度**组成。
  - ✧ 重构损失：衡量解码器输出图片与输入图片的差异，如均方误差 。
  - ✧ KL 散度：衡量近似后验分布$q(z, \mu, \sigma^2)$与隐变量 z 的先验分布 p(z)之间的差异。
    - ✓ p(z)指的是所有输入 x 的降维的隐变量 z 的分布，根据经验判断，可以为一个标准高斯分布，即$p(z) = \mathcal{N}(z; 0, I)$，均值为零向量，协方差矩阵是单位矩阵 I。将 p(z)设定为标准高斯分布也是因为它具有简单、对称且各向同性等特征。
    - ✓ 即希望在重构损失最小（解码器恢复出来的图片和原输入图片 x 最接近）的情况下，$D_{KL}(q(z|x) \,||\, p(z))$最小（隐变量 z 的分布尽可能接近一个标准高斯分布）。这样在训练完成后，就可以从训练出的$q(z, \mu, \sigma^2)$分布中采样一个 z，或者从 p(z)标准高斯分布采样也可以，然后通过解码器网络生成图片 x 了。
- 训练目标和过程

- ✧ 根据计算的损失函数值，进行反向传播计算，即计算编码器网络和解码器网络参数的梯度值，通过梯度下降等优化算法，不断调整编码器和解码器网络的参数，最后使 loss 函数损失最小化。
- ✧ VAE 训练目标是通过同时优化 loss 函数的两部分损失，能够学习到一种既能够有效重构输入数据，又能使潜在变量分布具有一定规律性的模型，从而实现对数据的压缩、表示学习和生成等功能

推理过程：

- 在训练完成后，就可以从训练出的$q(z,\mu,\sigma^2)$分布中采样一个 z，或者从 p(z)标准高斯分布采样也可以，然后通过解码器网络生成图片 x 了。

VAE 背后的数学原理：

- 已知数据集 X，如果能计算出隐变量的后验分布 p(z|x)，即 X 降维之后的特征数据 z 的分布，就可以直接从这个分布采样 z，训练一个 decoder 网络来恢复 x 即可。
- 但是 p(z|x)不可计算，根据贝叶斯公式 $p(z|x)=\frac{p(x|z)\,p(z)}{p(x)}$，而 p(x) 是边缘概率，其计算涉及到对所有可能的隐变量 z 进行积分，即 $p(x)=\int p(x|z)p(z)dz$ 。在实际情况中， z 往往是高维的，这个积分在大多数情况下没有解析解，数值计算的复杂度又非常高，所以很难直接得到 p(z|x) 。
- 因此设计了一个近似的后验概率 q(z|x)，通过编码器网络来训练，让 q(z|x)和 p(z|x)尽可能贴近，也就是这两个分布的 KL 散度$D_{KL}(q(z|x)\,||\,p(z|x))$最小化。
- 然后根据这两个分布的 KL 散度的定义，推导出 ELBO，得到 loss 函数定义。数学推导过程见：https://zhuanlan.zhihu.com/p/682709613

$$
\begin{aligned}
&D_{\mathrm{KL}}(q_\phi(\mathbf{z}|\mathbf{x})\|p_\theta(\mathbf{z}|\mathbf{x})) \\
&\quad=\int q_\phi(\mathbf{z}|\mathbf{x})\log\frac{q_\phi(\mathbf{z}|\mathbf{x})}{p_\theta(\mathbf{z}|\mathbf{x})}d\mathbf{z} \\
&\quad=\int q_\phi(\mathbf{z}|\mathbf{x})\log\frac{q_\phi(\mathbf{z}|\mathbf{x})p_\theta(\mathbf{x})}{p_\theta(\mathbf{z},\mathbf{x})}d\mathbf{z}\text{; Because } p(z|x)=p(z,x)/p(x) \\
&\quad=\int q_\phi(\mathbf{z}|\mathbf{x})\big(\log p_\theta(\mathbf{x})+\log\frac{q_\phi(\mathbf{z}|\mathbf{x})}{p_\theta(\mathbf{z},\mathbf{x})}\big)d\mathbf{z} \\
&\quad=\log p_\theta(\mathbf{x})+\int q_\phi(\mathbf{z}|\mathbf{x})\log\frac{q_\phi(\mathbf{z}|\mathbf{x})}{p_\theta(\mathbf{z},\mathbf{x})}d\mathbf{z}\text{; Because } \int q(z|x)dz=1 \\
&\quad=\log p_\theta(\mathbf{x})+\int q_\phi(\mathbf{z}|\mathbf{x})\log\frac{q_\phi(\mathbf{z}|\mathbf{x})}{p_\theta(\mathbf{x}|\mathbf{z})p_\theta(\mathbf{z})}d\mathbf{z}\text{; Because } p(z,x)=p(x|z)p(z) \\
&\quad=\log p_\theta(\mathbf{x})+\mathbb{E}_{\mathbf{z}\sim q_\phi(\mathbf{z}|\mathbf{x})}[\log\frac{q_\phi(\mathbf{z}|\mathbf{x})}{p_\theta(\mathbf{z})}-\log p_\theta(\mathbf{x}|\mathbf{z})] \\
&\quad=\log p_\theta(\mathbf{x})+D_{\mathrm{KL}}(q_\phi(\mathbf{z}|\mathbf{x})\|p_\theta(\mathbf{z}))-\mathbb{E}_{\mathbf{z}\sim q_\phi(\mathbf{z}|\mathbf{x})}\log p_\theta(\mathbf{x}|\mathbf{z})
\end{aligned}
$$

所以有：

$$D_{\mathrm{KL}}(q_\phi(\mathbf{z}|\mathbf{x})\|p_\theta(\mathbf{z}|\mathbf{x})) = \log p_\theta(\mathbf{x}) + D_{\mathrm{KL}}(q_\phi(\mathbf{z}|\mathbf{x})\|p_\theta(\mathbf{z})) - \mathbb{E}_{\mathbf{z}\sim q_\phi(\mathbf{z}|\mathbf{x})} \log p_\theta(\mathbf{x}|\mathbf{z})$$

重新排列一下等式得：

$$\log p_\theta(\mathbf{x}) - D_{\mathrm{KL}}(q_\phi(\mathbf{z}|\mathbf{x})\|p_\theta(\mathbf{z}|\mathbf{x})) = \mathbb{E}_{\mathbf{z}\sim q_\phi(\mathbf{z}|\mathbf{x})} \log p_\theta(\mathbf{x}|\mathbf{z}) - D_{\mathrm{KL}}(q_\phi(\mathbf{z}|\mathbf{x})\|p_\theta(\mathbf{z}))$$

等式的左边是我们学习真实分布的时候想要最大后的项，我们要最大化真实数据的对数似然，即最大化 $\log_\theta(x|z)$ ，同时最小化真实后验 $p_\theta(z|x)$ 和近似分布 $q_\phi(z|x)$ 之间的 KL 散度。所以上面等式的负值就是损失函数：

$$\begin{aligned} L_{\mathrm{VAE}}(\theta,\phi) &= -\log p_\theta(\mathbf{x}) + D_{\mathrm{KL}}(q_\phi(\mathbf{z}|\mathbf{x})\|p_\theta(\mathbf{z}|\mathbf{x})) \\ &= -\mathbb{E}_{\mathbf{z}\sim q_\phi(\mathbf{z}|\mathbf{x})} \log p_\theta(\mathbf{x}|\mathbf{z}) + D_{\mathrm{KL}}(q_\phi(\mathbf{z}|\mathbf{x})\|p_\theta(\mathbf{z})) \\ \theta^*,\phi^* &= \arg\min_{\theta,\phi} L_{\mathrm{VAE}} \end{aligned}$$

在Variational Bayesian方法中，这个损失函数被认为是变分下界，因为 KL 散度的值非负，所以 $-L_{VAE}$ 是 $\log p_\theta(x)$ 的下界，即：

$$-L_{\mathrm{VAE}} = \log p_\theta(\mathbf{x}) - D_{\mathrm{KL}}(q_\phi(\mathbf{z}|\mathbf{x})\|p_\theta(\mathbf{z}|\mathbf{x})) \leq \log p_\theta(\mathbf{x})$$

因此，通过最小化损失，我们可以最大化生成真实数据样本的概率的下界。

或者我们从 p(x)的分布定义开始推导：

$$p(X) = \int p(X|z)p(z)\,dz$$

$$\log p(X) = \log \int p(X|z)p(z)\,dz$$

$$\log p(X) = \log \int q(z|X)\frac{p(X|z)p(z)}{q(z|X)}\,dz$$

$$\mathbb{E}_{q(z|X)}[f(z)] = \int q(z|X)f(z)\,dz$$

因为有：

$$\log p(X) = \log \int q(z|X) \frac{p(X|z)p(z)}{q(z|X)} dz$$

$$\log p(X) = \log(\mathbb{E}_{q(z|X)}[f(z)])$$

根据 Jensen 不等式：

$$g\left(\mathbb{E}[X]\right) \geq \mathbb{E}[g(X)]$$

$$\log p(X) = \log(\mathbb{E}_{q(z|X)}[f(z)]) \geq \mathbb{E}_{q(z|X)}[\log(f(z))]$$

$$\log \int q(z|X) \frac{p(X|z)p(z)}{q(z|X)} dz \geq \int q(z|X) \log\left(\frac{p(X|z)p(z)}{q(z|X)}\right) dz$$

$$\mathbb{E}_{q(z|X)}\left[\log \frac{p(X|z)p(z)}{q(z|X)}\right]$$

.

$$\log p(X) \geq \mathbb{E}_{q(z|X)}\left[\log \frac{p(X|z)p(z)}{q(z|X)}\right]$$

$$\log \frac{p(X|z)p(z)}{q(z|X)} = \log p(X|z) + \log \frac{p(z)}{q(z|X)}$$

$$\mathbb{E}_{q(z|X)}\left[\log \frac{p(X|z)p(z)}{q(z|X)}\right] = \mathbb{E}_{q(z|X)}[\log p(X|z)] + \mathbb{E}_{q(z|X)}\left[\log \frac{p(z)}{q(z|X)}\right]$$

第一项 $\mathbb{E}_{q(z|X)}[\log p(X|z)]$ 表示的是重构误差的期望，即在近似分布 $q(z|X)$ 下的条件似然的期望值。

第二项 $\mathbb{E}_{q(z|X)}\left[\log \frac{p(z)}{q(z|X)}\right]$ 是 $q(z|X)$ 与 $p(z)$ 之间的 KL 散度。根据 KL 散度的定义，这一项可以直接写为：

$$-D_{\mathrm{KL}}(q(z|X) \parallel p(z))$$

$$\mathbf{ELBO} = \mathbb{E}_{q(z|X)}[\log p(X|z)] - D_{\mathrm{KL}}(q(z|X) \parallel p(z))$$

因此，损失函数定义成两个部分：

- ✧ 一部分为 X 的重建误差（即生成图片和原图片之间的 MSE。

- ✧ 另一部分是近似后验概率 q(z|x)与先验概率 p(z)之间的 KL 散度。

CVAE（Conditional VAE）：

- 在普通 VAE 中，并不利用标签信息，而是学会训练集数据的分布规律并生成新数据，比如使用一堆人脸的图片进行训练，就可以生成新的人脸图片。
- 如果要通过 text 描述来生成，比如“一只会飞的猫”，就需要使用带有条件信息的 CVAE（Conditional VAE），训练图片都带有文字标签。
  - ✧ 将图像数据和标签数据同时输入编码器。比如图像是猫的图片，标签是 “小橘猫”（一般会进行独热编码等处理 ），编码器会将二者信息融合处理，输出包含图像与标签信息的均值和方差。
    - ✓ 也可以采用不同的方式将 text 向量与 VAE 的潜在变量 z 进行融合，例如可以将语义向量与 z 拼接起来作为解码器的输入。
  - ✧ 然后在解码器输入中也引入标签信息，比如“一只会飞的猫”，与潜变量 z 一起作为输入。解码器结合这两部分信息，生成符合标签条件的图像 。