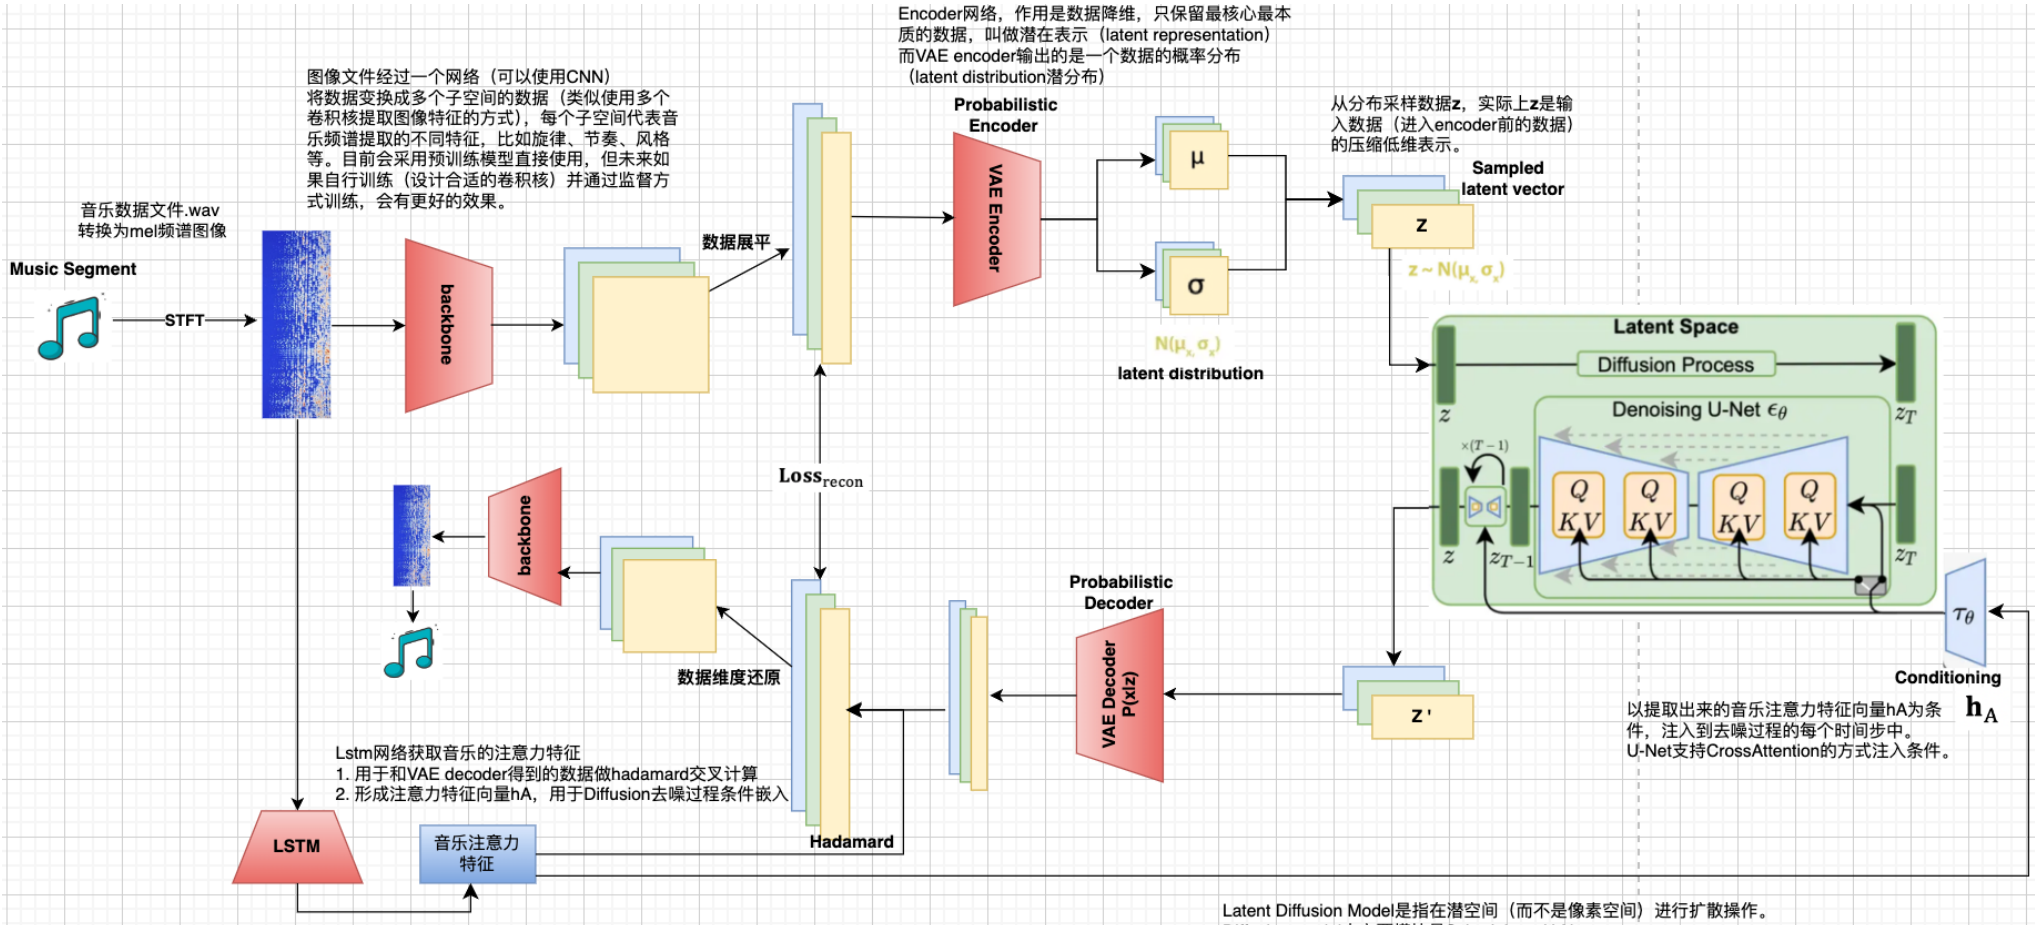



整体架构中存在的神经网络包括：

- Backbone：一个encoder/decoder结构，encoder利用卷积层获取频谱数据子空间表示。decoder从子空间表示上采样转换成频谱数据。（采用预训练模型）
- VAE：变分自编码器，采用预训练模型。
- CDM：Conditional Diffusion Model，采用预训练模型。
- LSTM：提取输入音乐的注意力特征（hA向量），需要训练。
- Attention：Denoising过程中通过CrossAttention方式注入hA条件，需要训练。

Latent Diffusion Model是指在潜空间（而不是像素空间）进行扩散操作。
Diffusion model中主要模块是Scheduler + U-Net。

- Scheduler负责加噪过程输出噪声每个step的噪声系数，噪声 = 随机生成噪声 * scheduler输出的系数。这是一个明确的计算过程，不需要训练。
- U-Net负责在去噪过程中预测噪声。结构特点是U型设计和跳层残差连接。U型网络指包含encoder/decoder的网络，encoder利用卷积进行下采样，逐步提取特征并降低空间维度。decoder进行上采样（如转置卷积）逐步恢复特征图的空间维度，再与从encoder步骤中的跳层残差连接（对应的编码器特征图）结合，一层层重建数据表示。
- U-Net 的最终输出是对噪声 $\hat{\epsilon}_t$ 的预测。这一输出是一个与输入图像 $x_t$ 相同尺寸的特征图，表示在时间步 $t$ 预测的噪声。
- 预测出噪声后，就可以计算这个时间步去噪后的图像

$$x_{t-1} = \frac{1}{\sqrt{\alpha_t}}\left(x_t - \frac{1-\alpha_t}{\sqrt{1-\bar{\alpha}_t}}\hat{\epsilon}_t\right)$$

Diffusion Model是最小化预测噪声和实际噪声之间的差异来学习，当每一步预测噪声与实际噪声差异最小时，也就代表了恢复出来的图片与原图最接近。

$$L(\theta) = \mathbb{E}_{x_0,\epsilon,t}\left[\|\epsilon - \hat{\epsilon}_t\|^2\right]$$